

ЛЕКЦИЯ 2

РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ



План:

1. Понятие EDA. Этапы EDA.
2. Основы описательной статистики в EDA.
3. Инструменты визуализации.

Инструменты визуализации (Graphical EDA)

matplotlib

 *seaborn*

Визуализация данных позволяет понять **паттерны**, **тренды** и **взаимосвязи** в данных через графику и диаграммы.

- **Диаграммное представление данных** облегчает понимание.
- **Упрощенное представление:** большие объемы сложных данных могут быть представлены в упрощенной и понятной диаграмме.
- **Раскрывает скрытые факты:** диаграммы помогают выявить факты и связи между данными, которые не заметны в необработанной/табличной форме.
- **Легко сравнивать:** диаграммы облегчают сравнение данных.

Типы диаграмм

- Pie Charts
- Bar Charts
- Histogram
- Box Plot
- Scatter Plot
- Heat map
- Line Graph
- side-by-side box-plots
- scatter plot matrix

Histograms (1)

ГИСТОГРАММА – графическое представление распределения данных по различным интервалам. Она позволяет оценить, как часто значения попадают в определенные диапазоны и какие имеются **пики** или **провалы в данных**.

Histograms (2)

- Представляет **распределение данных** в **числовой/непрерывной переменной** (оценивает распределение вероятностей числовой переменной).
- **Группирует значения** по серии интервалов (ячейки (бины) — обычно последовательные неперекрывающиеся подинтервалы, охватывающие диапазон данных)
- Показывает количество значений, попадающих в каждую ячейку (представлено высотой столбца).
- Нормализованная гистограмма показывает долю значений в каждой ячейке.

Histograms (3)

Гистограмма с соответствующим количеством/длиной интервалов (бинов) показывает:

- Где находятся данные.
- Где/каковы крайности.
- Каково распределение данных.
- Как распределены данные.
- Симметрично ли распределение или имеет перекося (влево или вправо).
- Также может обнаружить выбросы в данных, если таковые имеются.

Одномерные данные: Histograms vs Bar Plots

- В чем разница между гистограммой и столбчатой диаграммой?

Bar Plots (столбчатая диаграмма):

- Используется для категориальных переменных, чтобы показать частоту или пропорцию в каждой категории.
- Перевести данные из таблиц частот в графическое представление.

Histograms (гистограмма)

- Используется для визуализации распределения (форма, центр, диапазон, вариация) непрерывных переменных.

Scatter Plot (1)


ДИАГРАММА РАССЕЯНИЯ – график, в котором каждая точка представляет собой отдельное наблюдение и показывает **взаимосвязь между двумя переменными**. Это может помочь нам определить, есть ли какая-либо зависимость или корреляция между ними.

Scatter Plot (2)

Используя **график регрессии** (Seaborn), визуализируем связь между **Экономикой (ВВП на душу населения)** и **Индексом Счастья**: по мере роста **Экономики**, увеличивается **Индекс Счастья**, а также обозначает **положительную связь**

```
sns.regplot(x='Economy (GDP per Capita)',y='Happiness Score',data=happinessData)
```

```
<AxesSubplot:xlabel='Economy (GDP per Capita)', ylabel='Happiness Score'>
```



Scatter Plot (3)

- Показывает, как **две переменные связаны** друг с другом

=> выявляет **корреляции между переменными**.

- Если одна или обе переменные сильно искажены, то диаграммы рассеяния трудно исследовать, поскольку большая часть данных сосредоточена в небольшой части графика.

Примечание: Для этого нужно использовать какое-то преобразование

Scatter Plot vs PairPlot


Для исследования возможных зависимостей между признаками используется множество методов, но самые простые из них

- попарная диаграмма
- матрица корреляции.

Попарная диаграмма (Pairplot). Выбираются несколько признаков, зависимости между которыми нужно исследовать, и получается комбинированная диаграмма, включающая небольшую *диаграмму рассеяния (Scatter plot)* для каждой пары параметров. В диагональных клетках обычно выводятся графики или гистограммы соответствующих признаков.

ТЕПЛОВЫЕ КАРТЫ (HEAT MAP) (1)

ТЕПЛОВАЯ КАРТА – графическое представление матрицы данных, где цветовая шкала показывает *степень взаимосвязи между переменными*. Это помогает выявить *паттерны и зависимости* в больших наборах данных.



Величина коэффициента корреляции	0.1 - 0.3	0.3 - 0.5	0.5 - 0.7	0.7 - 0.9	0.9 - 1.0
Характеристика силы связи	слабая	умеренная	заметная	высокая	весьма высокая
		средняя		сильная	

ТЕПЛОВЫЕ КАРТЫ (HEAT MAP) (2)

Коэффициент корреляции всегда находится в интервале $[-1, 1]$, и его значение показывает, **насколько велика линейная зависимость между признаками**:

1: полная положительная линейная корреляция;

0: линейной корреляции нет, две переменные, скорее всего, не влияют друг на друга;

-1: полная отрицательная линейная корреляция.

Величина коэффициента корреляции	0.1 - 0.3	0.3 - 0.5	0.5 - 0.7	0.7 - 0.9	0.9 - 1.0
Характеристика силы связи	слабая	умеренная	заметная	высокая	весьма высокая

средняя

сильная

ТЕПЛОВЫЕ КАРТЫ (HEAT MAP) (3)


- Представляет **парные отношения** между атрибутами многомерных данных (**multivariate data**).
- Предоставляет численное значение корреляции между каждой переменной.

BOX PLOT: ОБНАРУЖЕНИЕ АНОМАЛИЙ

"Ящик с усами" не позволяет увидеть общую картину распределения, но предоставляет ценную информацию о его параметрах, особенно квантилях.

Квантиль – это такое значение признака, что заданный процент значений этого признака в наборе данных меньше этого квантиля. Например, квантиль 50% – это такое значение, что половина значений признака меньше, а вторая половина – больше него, этот квантиль называется **медианой**.


Квантили 0%, 25%, 50%, 75% и 100% называются **квартилями**, поскольку они делят область определения признака на 4 части.




“Усы” выводятся без учета **выбросов (outliers)** – значений, больших **$Q3+1.5*IQR$** или меньших **$Q1-1.5*IQR$** .

Выбросы скорее свидетельствуют об ошибках ввода данных, чем о реальных значениях признаков, и с ними надо что-то делать – например, **удалить**.

Скучковавшиеся окружности за пределами “усов” – это **аномалии**, и от них, как правило, избавляются с помощью **квантилей**!




На рисунке выбросы не показаны.



Side-by-side Box Plots

- Чрезвычайно полезно для сравнения двух или более переменных.



BAR CHART (Столбчатая диаграмма)

- Обычно используется для малом количестве категорий **номинальных** и **порядковых** переменных.
- Разные столбцы (обычно окрашенные/затененные по-разному) для различных значений(уровней, категорий, символов) переменной.
- Высота столбца представляет частоты каждого символа (значения).

PIE CHART (Круговая диаграмма)

- используется для **номинальных** и **порядковых** переменных с относительно небольшим числом дискретных категорий (**до 5**)

Для оптимизации процесса EDA доступны библиотеки Python, которые автоматизируют задачи EDA и **генерируют аналитические данные** несколькими строками кода:

- **Pandas-profiling**
- **Sweetviz**
- **Autoviz**
- **dataprep**
- **KLib**
- **dabl**
- **speedML**
- **data tile**
- **Bamboolib**
- **D-Tale**

Функциональные возможности библиотек:

- визуализация данных,
- сводные отчеты,
- корреляционный анализ
- манипулирование данными

Pandas-profiling

Библиотека устанавливается стандартным способом **pip**

```
pip install pandas-profiling
```

```
# импорт библиотек
```

```
import pandas as pd
```

```
import pandas_profiling
```

```
# загружаем датасет
```

```
df = pd.read_csv('adult.data.csv')
```

```
# создаём отчёт
```

```
profile = df.profile_report(title='Pandas Profiling Report', progress_bar=False)
```

```
# смотрим отчёт в HTML формате
```

```
profile
```