


ОБУЧЕНИЕ БЕЗ УЧИТЕЛЯ. МЕТРИЧЕСКИЕ МОДЕЛИ. ЗАДАЧА КЛАСТЕРИЗАЦИИ



План:

1. Обучение без учителя (Unsupervised Learning).
Метрические модели.
2. Задача кластеризации. Постановка задачи кластеризации.
3. Методы оценки качества кластеризации.
4. Алгоритм кластеризации k-средних (k-means).
5. Иерархическая кластеризация.
6. Основанная на плотности кластеризация (DBSCAN).
7. Гауссовы смеси (Gaussian Mixture Models, GMM).
8. Алгоритм кластеризации Affinity Propagation (AP).

МЕТОДЫ КЛАСТЕРИЗАЦИИ. Кластеризация *неразмеченных* данных
МОЖНО ВЫПОЛНИТЬ С ПОМОЩЬЮ МОДУЛЯ **sklearn.cluster**

2.3. Кластеризация

2.3.1. Методы кластеризации

(Алгоритмы кластеризации)

2.3.2. K-means (К-средних)

2.3.3. Affinity propagation (AP,

метод распространения

близости)

2.3.4. Средний сдвиг (Mean Shift)

2.3.5. Спектральная

кластеризация

2.3.6. Иерархическая

кластеризация

2.3.7. DBSCAN

2.3.8. HDBSCAN

2.3.9. OPTICS

2.3.10. BIRCH

2.3.11. Оценка

производительности

кластеризации




<https://scikit-learn.ru/clustering/>

O'REILLY®

Прикладное машинное обучение без учителя

с использованием Python



Часть II. Обучение без учителя с использованием библиотеки Scikit-learn

Глава 3. Снижение размерности


Глава 4. Обнаружение аномалий

Глава 5. Кластеризация

Глава 6. Сегментирование групп

Анкур Пател

<https://academy.yandex.ru/handbook/ml/article/klasterizaciya>




Этапы проведения кластерного анализа

5



ТИПЫ КЛАСТЕРНЫХ СТРУКТУР




Сгущения: внутрикластерные расстояния, как правило, меньше межкластерных.



Ленты: для любого объекта найдётся близкий к нему объект того же кластера, в то же время существуют объекты одного кластера, которые не являются близкими.

ТИПЫ КЛАСТЕРНЫХ СТРУКТУР



Кластеры с центром: в каждом кластере найдётся объект, такой, что почти все объекты кластера лежат внутри шара с центром в этом объекте.



Кластеры могут соединяться перемычками, что затрудняет работу многих алгоритмов кластеризации.

ТИПЫ КЛАСТЕРНЫХ СТРУКТУР



Кластеры могут накладываться на разреженный фон из редких нетипичных объектов.



Кластеры могут перекрываться.

ТИПЫ КЛАСТЕРНЫХ СТРУКТУР



Кластеры могут образовываться не по принципу сходства, а по каким-либо иным, заранее неизвестным, свойствам объектов. Стандартные методы кластеризации здесь бессильны.



Кластеры могут вообще отсутствовать. В этом случае надо применять не кластеризацию, а иные методы анализа данных.

Примеры прикладных задач кластеризации

APPLICATIONS OF CLUSTERING



Market Segmentation

Input Image: cameraman



segmented Image: cameraman



Image Segmentation




Search Engines



Anomaly Detection

Примеры прикладных задач кластеризации

Анализ геоданных. В мобильных приложениях, собирающих геоданные пользователей, часто требуется понять, где именно пользователь находился. GPS-координаты известны с некоторой погрешностью, пользователь тоже обычно движется, поэтому вместо точного положения часто приходится иметь дело с роем точек.



МЕТОДЫ ОЦЕНКИ КАЧЕСТВА КЛАСТЕРИЗАЦИИ

2.3. Кластеризация

2.3.1. Методы кластеризации

(Алгоритмы кластеризации)

2.3.2. K-means (K-средних)

2.3.3. Affinity propagation (AP,
метод распространения
близости)

2.3.4. Средний сдвиг (Mean Shift)

2.3.5. Спектральная
кластеризация

2.3.6. Иерархическая
кластеризация


2.3.7. DBSCAN

2.3.8. HDBSCAN


2.3.9. OPTICS

2.3.10. BIRCH


2.3.11. Оценка
производительности
кластеризации



Кластеризация на основе К средних (K-Means clustering)



Before K-Means



After K-Means

K-means часто называют алгоритмом Ллойда

Классический алгоритм k-means

Алгоритм кластеризация с помощью алгоритма k -средних следующий:

1) Выбрать начальное приближение Y центров всех кластеров:

$$y \in Y: \mu_y$$

2) Отнести каждый объект x_i к одному из кластеров, исходя из минимума метрики расстояния $p(x_i, \mu_y)$:

do:

$$y_i := \underset{y \in Y}{\operatorname{argmin}} p(x_i, \mu_y), i = 1, \dots, l;$$

3) Вычислить новое положение центров каждого из кластеров, пока метки y_i не перестанут изменяться.

$$\mu_{yj} = \frac{\sum_{i=1}^l [y_i = y] f_i(x_i)}{\sum_{i=1}^l [y_i = y]}, y \in Y, j = 1, \dots, n$$

L — метрическое пространство размерности.

Алгоритм k-средних

Алгоритм 8.1. $KMeans(D, K)$ – кластеризация методом K средних с применением евклидова расстояния Dis_2

Вход: данные $D \subseteq \mathbb{R}^d$; число кластеров $K \in \mathbb{N}$.


Выход: средние K кластеров $\mu_1, \dots, \mu_K \in \mathbb{R}^d$.

- 1 случайным образом инициализировать K векторов $\mu_1, \dots, \mu_K \in \mathbb{R}^d$;
- 2 **repeat**
- 3 отнести каждую точку $\mathbf{x} \in D$ к кластеру $\operatorname{argmin}_j Dis_2(\mathbf{x}, \mu_j)$;
- 4 **for** $j = 1$ до K **do**
- 5 $D_j \leftarrow \{\mathbf{x} \in D \mid \mathbf{x} \text{ отнесена к кластеру } j\}$;
- 6 $\mu_j = \frac{1}{|D_j|} \sum_{\mathbf{x} \in D_j} \mathbf{x}$;
- 7 **end**
- 8 **until** $\mu_1, \dots, \mu_K$ перестают изменяться;
- 9 **return** $\mu_1, \dots, \mu_K$;

Ключевые идеи для кластеризации по методу k -средних

- **Число** требующихся **кластеров K** выбирается пользователем.
- Алгоритм совершенствует кластеры путем итеративного отнесения записей к ближайшему центру кластера, пока отнесения к кластерам не перестанут изменяться.
- Над выбором K обычно доминируют соображения практического характера; статистически обусловленного оптимального количества кластеров не существует.
- Следует нормализовать данные при работе с алгоритмами кластеризации, такими как k -means, поскольку такие алгоритмы используют измерения на основе расстояния для выявления сходства между точками данных.
- Из-за итеративного характера алгоритма k -means и случайной инициализации центроидов k -means рекомендуется использовать разные инициализации центроидов.
- Двумя альтернативами кластеризации k -средних являются кластеризация k -medoids и иерархическая кластеризация.

Иерархическая кластеризация (Hierarchical Clustering)



Типы связей (расстояние между двумя кластерами)

- **Single Linkage**

$$D(c_1, c_2) = \min D(x_1, x_2)$$


Minimum distance or distance between closest elements in clusters



- **Complete Linkage**

$$D(c_1, c_2) = \max D(x_1, x_2)$$


Maximum distance between elements in clusters



- **Average Linkage**

$$D(c_1, c_2) = \frac{1}{|c_1|} \frac{1}{|c_2|} \sum \sum D(x_1, x_2)$$

Average of the distances of all pairs



- **Centroid Method**


Combining clusters with minimum distance between the centroids of the two clusters



- **Ward's Method**


- Combining clusters where increase in within cluster variance is to the smallest degree.

- Objective is to minimize the total within cluster variance



Основанная на плотности кластеризация DBSCAN.

Кластеризация пространственных данных.



Пространственные данные

Пространственные данные и геоданные часто используются как взаимозаменяемые термины, но между ними есть некоторые различия.


1. Пространственные данные: более широкий термин, который охватывает любые данные, связанные с пространственным расположением объектов.

2. Геоданные: подмножество пространственных данных, которое конкретно связано с географическими объектами и их расположением на поверхности Земли. Геоданные обычно имеют привязку к координатам (широта и долгота).

Пространственные данные

При работе с пространственными данными их часто полезно превратить в кластеры. Например, чтобы:

- выявить “горячие точки” — места наибольшей плотности заболеваний, преступности, ДТП;
- объединить районы со схожими социальными условиями;
- определить области заболеваний;
- выявить места с одним типом землепользования.



Пример кластеризации пространственных данных: в **кластеры** объединились **кварталы, схожие по социально-экономическим условиям**

Figure 4: Socioeconomic clustering of the residential neighborhoods.

Плотностные алгоритмы

Основное отличие плотностных алгоритмов от разделительных заключается в их способности определять:

- кластеры произвольной формы;
- необходимое количество кластеров.

Плотность в этом алгоритме определяется количеством точек, а также расстоянием, на котором эти точки находятся.

Плотностный подход кластеризации

Плотностный подход — это метод кластеризации, при котором **кластеры** определяются как **области пространства с высокой плотностью точек**, отделённые от других кластеров областями с **низкой плотностью**.

Основная идея заключается в том, что:

Кластер — это связная область, где плотность точек превышает заданный порог,

Шум (Noise) — точки, расположенные в областях с недостаточной плотностью

Ключевые принципы плотностного подхода

1. Локальная плотность: кластер формируется вокруг **ядерных точек (core points)**, у которых в ε -окрестности находится не менее **MinPts соседей**.

2. Достижимость. Точка принадлежит кластеру, если она **достижима из любой ядерной точки этого кластера** через цепочку соседей.

Пример: если x_j находится в ε -окрестности x_i , а x_i — ядерная точка, то x_j включается в кластер.

3. Автоматическое определение числа кластеров. Число кластеров не задаётся заранее, а определяется алгоритмом на основе плотности данных.

Ключевые принципы плотностного подхода

4. Произвольная форма кластеров. В отличие от k-means, кластеры могут быть любой формы (например, "полумесяцы", "кольца").

Кластеризация k-средних:



в то время как DBSCAN выдаст:



Гиперпараметры DBSCAN

На вход алгоритму DBSCAN подаётся набор точек, параметры ϵ (радиус окрестности) и MinPts (минимальное число точек в окрестности).

Основные гиперпараметры DBSCAN: ϵ и MinPts, которое может быть в одном кластере. *Эти параметры обычно подбираются исследователем индивидуально для каждой задачи подбора данных параметров*

ϵ (радиус окрестности): если расстояние между любыми двумя точками меньше или равно заданному радиусу, эти точки считаются соседними. Радиус окрестности необходимо задавать исходя из расстояния между точками.

MinPts (минимальное количество соседей (точек) в радиусе для формирования кластера): чем больше набор данных, тем больше точек должно быть выбрано.

Пограничная точка (Border Point) — точка, которая не является ядром, но находится в пределах ε от ядровой точки.

Шум (Noise Point) — точка, которая не является ни ядром, ни пограничной точкой.

Ядро (Core Point) — точка, которая имеет не менее соседей (точек) в пределах радиуса ε .

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) – алгоритм кластеризации, основанный на плотности, который группирует точки в кластеры на основе их плотности и расстояния друг от друга.

Алгоритм DBSCAN предполагает, что часть точек из набора данных не принадлежат ни одному из кластеров, а являются шумом. В то же время никаких центроидов нет, кластеры формируются на основе близости.

Математическая формализация

Для алгоритма **DBSCAN** (плотностный подход) кластер определяется как:

$$C = \{x_i \mid \exists \text{ путь из ядерных точек } x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x_i\},$$

где:

- x_1 — ядерная точка ($|N_\varepsilon(x_1)| \geq \text{MinPts}$),
- $x_{i+1} \in N_\varepsilon(x_i)$ (попадает в ε -окрестность предыдущей точки).

Условия:

- Если $|N_\varepsilon(x_i)| < \text{MinPts}$, точка считается **шумом**.
- Граничные точки (не ядерные, но достижимые из ядра) включаются в кластер.

Сравнение с другими подходами кластеризации

Подход	Определение кластера	Примеры алгоритмов
Плотностный	Области с высокой плотностью	DBSCAN, OPTICS
Центроидный	Близость к центру кластера	K-means
Иерархический	Вложенные группы (дендрограмма)	Agglomerative Clustering
Распределённый	Подгонка под вероятностное распределение	Gaussian Mixture (GMM)

Оценка качества DBSCAN

Метрики для плотностных алгоритмов:

- **Silhouette Score:** Оценивает компактность и разделимость. Менее эффективен для DBSCAN, чем для K-means.
- **DBCV (Density-Based Cluster Validity):**
 - Учитывает плотность и связность кластеров.
 - Лучше подходит для DBSCAN.


Внешние метрики:

- **Adjusted Rand Index (ARI),**
- **Normalized Mutual Information (NMI).**

Алгоритм DBSCAN

Оригинальный алгоритм неплохо описан в Википедии.

<https://ru.wikipedia.org/wiki/DBSCAN>



```
from sklearn.cluster import DBSCAN
```

<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html>

Преимущества DBSCAN

1. **DBSCAN** — мощный метод для данных с нелинейной структурой.
2. **Обнаружение кластеров сложной формы** (не только сферических, как в k-means).
3. **Устойчивость к шуму:** автоматическое выделение выбросов.
4. **Не требует задания числа кластеров** (в отличие от k-means).

Недостатки DBSCAN

- 1. Плохая работа с данными разной плотности (решение: HDBSCAN).**
- 2. Чувствительность к параметрам ϵ и MinPts.**
- 3. Сложность на больших данных.** Сложность вычислений: Для больших наборов данных алгоритм может потребовать значительных вычислительных ресурсов из-за необходимости вычисления расстояний между всеми точками
- 4. Не подходит для высокоразмерных данных (поэтому необходимо предварительно уменьшать размерность данных).**

Альтернативы и модификации DBSCAN


- **OPTICS:** Улучшенная версия DBSCAN для данных с **разной плотностью**.
- **HDBSCAN:** Автоматический выбор ϵ + иерархическая кластеризация.

Рекомендации:

- Для данных с разной плотностью попробуйте **HDBSCAN**.

Кластеризация на основе смеси гауссовых распределений.


Гауссовы смеси (Gaussian Mixture Model, GMM)



Гауссовы смеси (Gaussian Mixture Model, GMM)

Другая модель для кластеризации — **гауссовы смеси**, идея которых в том, что кластер для точки будет определяться **не по расстоянию до центроида**, а **по вероятности** (для каждой точки будем знать вероятности ее принадлежности к каждому из кластеров — выбираем кластер, соответствующий максимальной вероятности).

Модель гауссовых смесей использует **вероятностный подход к кластеризации**. В отличие от методов, таких как k-средние (которые основываются на расстоянии до центроидов), GMM предполагает, что **данные генерируются из смеси нескольких гауссовских распределений**.



Гауссовы смеси (Gaussian Mixture Model, GMM)

В задаче кластеризации, например, при использовании модели Гауссовых смесей, **скрытые переменные** могут представлять **принадлежность** каждого наблюдения к определенному кластеру. Хотя мы видим только данные, сами **кластеры являются скрытыми переменными**.

Скрытые (латентные) переменные в ML — это **переменные, которые не наблюдаются напрямую**, но влияют на наблюдаемые данные. Они представляют собой скрытые факторы или структуры, которые **могут объяснять зависимости между наблюдаемыми переменными**.

В контексте статистики и ML латентные переменные часто используются для моделирования сложных явлений.

ЕМ-алгоритм (Expectation-Maximization)

ЕМ-алгоритм — это итеративный метод, используемый для **оценки параметров статистических моделей**, когда данные имеют **скрытые (латентные) переменные**. Он особенно полезен в задачах, связанных с кластеризацией и оценкой параметров моделей с неполными данными.

Этапы ЕМ-алгоритма:

1. **Инициализация:** задать произвольные значения параметров модели.
2. **Е-шаг (Expectation):** вычислить ожидаемые значения скрытых переменных, основываясь на текущих параметрах модели. Это делается с использованием полной вероятностной модели.
3. **М-шаг (Maximization):** На этом этапе параметры модели обновляются, чтобы максимизировать ожидаемую полную логарифмическую вероятность, рассчитанную на предыдущем шаге.
4. **Повторение:** Процесс повторяется, пока не будет достигнута сходимость (параметры перестанут существенно изменяться).

Математическая постановка

GMM — это **вероятностная модель**, представляющая данные как смесь K гауссовых (нормальных) распределений.

Каждый кластер описывается:

- **Средним (μ_k)** — центр кластера,
- **Ковариационной матрицей (Σ_k)** — форма кластера,
- **Весовым коэффициентом (π_k)** — априорная вероятность кластера.

Формула плотности смеси:

$$p(x) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(x \mid \mu_k, \Sigma_k),$$

где:

- $\mathcal{N}(x \mid \mu_k, \Sigma_k)$ — плотность k -го гауссова распределения,
- π_k — вес k -го распределения ($\sum_{k=1}^K \pi_k = 1$).

Алгоритм GMM (ЕМ-алгоритм)

Объект [GaussianMixture](#) реализует алгоритм Ожидание-максимизация (Expectation-Maximization, EM) для обучения гауссовых моделей.




```
from sklearn.mixture import GaussianMixture
```

2.1. Модели гауссовских смесей (Gaussian mixture models)

2.1.1. Гауссовская смесь (Gaussian Mixture)

2.1.2. Вариационная байесовская гауссовская смесь

<https://scikit-learn.ru/2-1-gaussian-mixture-models/>



GMM (ЕМ-алгоритм)

Рассмотрим применение ЕМ-алгоритма для задачи кластеризации с использованием смеси гауссовских распределений (GMM).

Шаг 1: Инициализация

- Задаем **число кластеров K** ,
- Случайно выбираем параметры μ_k, Σ_k, π_k .

Шаг 2: Е-шаг

Вычисляем **апостериорные вероятности** принадлежности точки x_i (каждого наблюдения) к кластеру k :

$$\gamma_{ik} = \frac{\pi_k \cdot \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}.$$

GMM (ЕМ-алгоритм)

Шаг 3: М-шаг (Maximization).

Пересчитываем параметры, максимизируя правдоподобие:

$$\mu_k = \frac{\sum_{i=1}^N \gamma_{ik} x_i}{\sum_{i=1}^N \gamma_{ik}}, \quad \Sigma_k = \frac{\sum_{i=1}^N \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_{i=1}^N \gamma_{ik}}, \quad \pi_k = \frac{\sum_{i=1}^N \gamma_{ik}}{N}.$$

Шаг 4: Критерий остановки.

Изменение логарифмического правдоподобия меньше порога:

$$\log p(X \mid \mu, \Sigma, \pi) = \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(x_i \mid \mu_k, \Sigma_k) \right).$$

Особенности кластеризации

1. Гибкость формы кластеров:

Ковариационная матрица Σ_k позволяет описывать эллипсоидальные, вытянутые (или сферические кластеры). **Варианты Σ_k :**

- 'full': каждый кластер имеет свою матрицу (произвольная форма),
- 'tied': общая матрица для всех кластеров,
- 'diag': диагональная матрица (оси параллельны осям координат),
- 'spherical': $\Sigma_k = \sigma_k^2 I$ (сферические кластеры).

2. Вероятностная принадлежность:

Каждая точка может принадлежать нескольким кластерам с **разными вероятностями (soft clustering)**.

3. Автоматический учет плотности:

Кластеры могут иметь разную плотность и размер.

Сравнение с k-means		
Критерий	GMM	K-means
Форма кластеров	Эллипсоидальная	Сферическая
Тип кластеризации	Вероятностная (soft)	Жёсткая (hard)
Оптимизация	ЕМ-алгоритм (правдоподобие)	Минимизация SSE
Чувствительность	К инициализации	К выбросам

Недостатки

1. Чувствителен к **инициализации**.
2. Требуется задания числа кластеров K .
3. Высокая вычислительная сложность
4. Плохо масштабируется на большие данные.

Преимущества



1. Моделирует кластеры **любой формы**.
2. **Вероятностный вывод** (soft clustering).
3. Работает с **разной плотностью** данных.
4. Устойчив к **шумам**.

Применение

Модели Гауссовых смесей находят широкое применение в различных областях:


- **Кластеризация:** GMM может использоваться для кластеризации данных, где каждое кластерное представление соответствует одной из компонент модели.
- **Анализ изображений:** Используется для сегментации изображений и распознавания объектов.
- **Обработка сигналов:** Применяется в задачах распознавания речи и анализа временных рядов.

Алгоритм кластеризации Affinity Propagation (AP)

Affinity cluster sample propagation algorithm	
DBSCAN cluster algorithm sample	

Affinity Propagation (AP)

- ❑ **Affinity Propagation (AP)** — это алгоритм кластеризации, который **автоматически** определяет **число кластеров** и их **наиболее репрезентативные точки (exemplars)**, основываясь на концепции «передачи сообщений» между точками данных.
- ❑ Распространение сходства основано на концепции «передачи сообщений» между точками данных для идентификации центров кластеров, называемых **образцами**.
- ❑ **Образцы (exemplars)**: это «лидеры» групп; каждая группа будет иметь одну репрезентативную точку данных (образец), а другие точки данных будут назначены этой группе на основе сходства.



Affinity Propagation (AP)

Ключевые понятия:

- Матрица сходства или подобия (Similarity Matrix) S :

$$s(i, k) = -\|x_i - x_k\|^2, \quad i \neq k$$

- $s(i, k)$ — сходство между объектами x_i и x_k , т.е. схожесть между точкой i и центроидом k . Обычно это отрицательное значение расстояния между ними.
- Диагональные элементы $s(k, k)$ — “предпочтение” (preference) точки x_k стать центром кластера (обычно выбирается как медиана или минимум матрицы сходства).
- В алгоритме AP используются 2 типа сообщений:
 - Сообщение «от точки до центроида» Responsibility (ответственность) $r(i, k)$: определяет, насколько хорошо точка i подходит для того, чтобы быть представителем (центроидом) кластера k .
 - Сообщение «от центроида до точки» Availability (доступность) $a(i, k)$: показывает, насколько вероятно, что центроид k будет выбран для точки i .

Affinity Propagation (AP)

Ключевые понятия:

- **Дистанция:** обычно используется евклидово расстояние или другая мера расстояния для вычисления схожести между точками.

Алгоритм Affinity Propagation (AP)

Шаг 1: Инициализация

- Задаем **матрицу сходства** S и параметр **damping** (затухание, обычно 0.5–0.9).
- **Диагональ** $s(k,k)$ — предпочтение стать центром (чем выше, тем вероятнее).
- Инициализация сообщений responsibility и availability нулями:
 $r(i, k) = 0, a(i, k) = 0$

Шаг 2: Итеративное обновление сообщений

Для каждой пары точек (i,k) :

1. Обновление

$$r(i, k) = s(i, k) - \max_{k' \neq k} (a(i, k') + s(i, k'))$$

2. Обновление

$$a(i, k) = \min \left(0, r(k, k) + \sum_{i' \neq k} \max(0, r(i', k)) \right)$$

Для диагональных элементов:

$$a(k, k) = \sum_{i' \neq k} \max(0, r(i', k))$$

Алгоритм Affinity Propagation (AP)

Шаг 3: Определение кластеров

После сходимости (изменения сообщений меньше порога):

- Точка x_k становится **центроидом**, если $a(k,k)+r(k,k)>0$.
- Каждая точка x_i приписывается к ближайшему центроиду.

Шаг 4: Итерация

- Повторяйте шаги 2-3 до тех пор, пока сообщения не стабилизируются (т.е. изменения в сообщениях становятся незначительными) или пока не достигнуто максимальное количество итераций.

Шаг 5. Формирование кластеров

- Кластеры формируются на основе выбранных центроидов.

Алгоритм Affinity Propagation (AP)

Algorithm 1 Affinity propagation

function AFFINITY PROPAGATION(**S**, *maxiterations*)

R, **A** $\leftarrow$ **0**, **0**

while $i < \text{maxiterations}$ **do** {

$$\forall i, k : r(i, k) \leftarrow s(i, k) - \max_{\forall j: j \neq k} (a(i, j) + s(i, j)) \quad (1)$$

$$\forall i, k, i \neq k : a(i, k) \leftarrow \min \left(0, r(k, k) + \sum_{\forall j: j \neq i, j \neq k} \max(0, r(j, k)) \right) \quad (2)$$

$$\forall k : a(k, k) = \sum_{\forall j: j \neq k} \max(0, r(j, k)) \quad (3)$$

}

$$\forall i : c_i \leftarrow \arg \max_k (a(i, k) + r(i, k)) \quad (4)$$

return ($c_1, c_2 \dots c_N$)

Особенности кластеризации

1. Автоматическое определение числа кластеров:

- Число кластеров зависит от параметра **preference** (диагональ $s(k,k)$).
- Чем **выше preference**, тем **больше кластеров**.

2. Выбор прототипов (exemplars):

- **Центры кластеров** — реальные точки данных (а не средние, как в k-means).
- Устойчивость к шумам: **“плохие” прототипы исключаются**.

3. Гибкость формы кластеров:

- Кластеры могут быть произвольной формы (как в DBSCAN).

Преимущества

1. Не требует задания числа кластеров.
2. Устойчив к шумам и выбросам.
3. Прототипы — реальные точки данных.
4. Работает с произвольной формой кластеров.

Недостатки

1. Чувствителен к выбору **preference**.
2. Плохо масштабируется на большие данные.
3. Требуется настройки **damping**.

Сравнение с K-means и DBSCAN			
Критерий	Affinity Propagation	K-means	DBSCAN
Число кластеров	Автоматическое	Задается вручную	Автоматическое
Центры кластеров	Реальные точки (exemplars)	Средние значения	Нет явных центров
Форма кластеров	Произвольная	Сферическая	Произвольная

Применение

Биоинформатика: Кластеризация генов или белков.

Компьютерное зрение: Группировка похожих изображений.

Социальные сети: Выявление сообществ пользователей.